

Anteproyecto de Tesina de Licenciatura

-----Título del proyecto-----

Director de tesina: Dr. Héctor Gilberto Vázquez López

Candidato: Jesús Jacob García Medrano

1. Introducción

El proyecto del genoma humano, comenzado a finales de la década de 1980, era promovido como el proyecto final para descubrir la "huella digital de la vida". Se pensaba que el proyecto estaría terminado para el 2005 sin embargo, lograr descubrir la "huella digital de la vida" para ese año era bastante cuestionable. Para ese entonces ya se tenían secuenciados algunos genomas de bacterias y levaduras, y se sabía que, de la función biológica de los genes, entre el 30 % al 50 % permanecían aun sin caracterizar. A todo esto había que sumar que los genes y sus productos eran solo componentes individuales de un sistema biológico entero, el cómo se comporta cada uno de estos componentes no es suficiente para entender el sistema completo [14].

Es por esto que surge la necesidad de crear una plataforma para efectuar el post-análisis de toda esta nueva información, es decir realizar acercamientos experimentales e informáticos para sistemáticamente descubrir las interacciones y rutas génicas y metabólicas. Así surge la enciclopedia Kyoto de genes y genomas (KEGG), siendo una plataforma en línea para llevar a cabo este post-análisis [14]. KEGG partió teniendo tres objetivos:

1. Computarizar el conocimiento actual de las rutas génicas y metabólicas de observaciones experimentales.
2. Mantener un catálogo de genes para cada organismo que ha sido secuenciado, y cada componente del catálogo que sea mapeado a las rutas de KEGG.
3. Desarrollar nuevas tecnologías informáticas que estén asociadas con rutas e interacciones.

La disponibilidad de genomas completos provenientes de distintos organismos para su análisis comparativo provee una nueva perspectiva sobre las relaciones entre los genes [17]. Tener un inventario conocido de genes conservados responsables de las funciones de gestión interna en la célula y entender la base genética en las diferencias de estas funciones a través de distintos linajes es central para entender la vida misma, al menos a un nivel de célula individual [24]. Koonin [17] plantea que debería ser posible entonces reconstruir la historia evolutiva de cada gen (siempre y cuando se tenga secuenciado todo el genoma que lo contenga).

A toda esta nueva información es natural extenderle los conceptos de biología evolutiva, principalmente, definiciones como: analogía, homología y sus derivados, como ortología y paralogía [5]. La homología, en su definición más general, designa una relación de descendencia común entre cualquier entidad, sin alguna especificación adicional sobre el escenario evolutivo. De acuerdo con esto, las entidades estarían relacionadas por homología, si hablamos de genes, estos serían llamados homólogos [17]. Y a su vez habría dos tipos de homología (en sentido amplio): una en la que homología es resultado de una duplicación génica y entonces ambas copias descenderían a lo largo de la historia evolutiva de un organismo, estos genes deberían ser llamados parálogos, y el otro tipo sería la homología como resultado de la especiación y por lo tanto la historia del gen refleja las especies, a estos genes se les debería de llamar ortólogos [5].

Este ultimo concepto de homología se ha prestado para diversas confusiones en su uso. A finales de la década de 1990, Ouzounis [21] notó un incremento muy grande en el número de artículos que utilizaron el término “ortología” y algunos de ellos usaron libremente este concepto sobre genes que eran funcionalmente equivalentes entre especies, sin explícitamente hacer referencia a un evento de especiación. Términos como ortología, son conceptos que se definen respecto a la evolución y no a su función [26]. Es aquí donde surge un malentendido de interpretación en la conexión entre ortología y función biológica o bioquímica, ya que, si bien, una propiedad crucial de los ortólogos, la cual es teóricamente posible y empíricamente soportada, es que realizan funciones equivalentes en el respectivo organismo; existen situaciones en donde la misma función bioquímica es realizada por proteínas que ni siquiera son homólogas [17]. Este problema (aunque indirectamente) también fue explorado por Henrissat y Davies [7] cuando describieron brevemente la dificultad de crear un sistema de clasificación para proteínas basándose en su sustrato unicamente. Eso sin mencionar que implícitamente se estaría reconociendo que se conocen todos los sustratos y reacciones químicas de la o las proteínas en cuestión [22]. Por lo tanto es poco aconsejable hablar de “homólogos funcionales” en los que la equivalencia funcional se toma como un sustituto de la ortología [17].

Es aquí, después de presentar algunos antecedentes de la problemática en el fluctuante uso e interpretación del término “ortología” que volvemos a la base de datos KEGG, ya que esta identifica a los ortólogos no solo por similitud en la secuencia de genes individuales, sino que también evalúa si están presentes todos los genes que conforman un grupo funcional, como una subruta metabólica conservada o un complejo molecular [13]. Estos genes se organizan en tablas de grupos de ortólogos, donde cada tabla representa tres características: si un organismo contiene el conjunto completo de genes que constituyen un grupo funcional, si dichos genes están físicamente agrupados en el cromosoma y cuáles son los genes ortólogos entre diferentes organismos [13].

El estudio y propuesta de grupos ortólogos ha sido una de las prácticas más frecuentes por los biólogos moleculares, incluso antes del desarrollo de la genómica comparada, análisis y estudio de las familias génicas [25]. Las familias génicas son grupos de genes que descienden de un ancestro en común y retienen cierta similitud en su secuencia y a menudo tienen una función compartida [2]. El concepto de familia génica aplica tanto a ambos genes dentro de un genoma (parálogos) y genes relacionados entre genomas (ortólogos y parálogos) [2].

Este estudio parte de el trabajo realizado por el Dr. Héctor Gilberto Vázquez López en su trabajo posdoctoral [25] en el que buscó revisar las relaciones evolutivas entre varios genes ortólogos de β -galactosidasas apoyándose en diversos análisis de estructura terciaria y primaria. Las β -galactosidasas son enzimas conocidas y con función metabólica relacionada a la galactosa y lactosa. Esta enzima cataliza tres reacciones químicas, primero, puede escindir la lactosa para formar glucosa y galactosa. Segundo, la enzima puede catalizar la transglucosilación de lactosa a alolactosa, y tercero, puede escindir la alolactosa en monosacáridos [12]. La β -galactosidasa es un homotetrámero conformado por más de 1000 aminoácidos por monómero [6, 12].

2. Planteamiento del problema

3. Objetivos

General

Evaluar la validez evolutiva del grupo de ortólogos anotados como 6-fosfo- β -galactosidasas (GH1) en KEGG, mediante el análisis de arquitectura de dominios y conservación evolutiva, para determinar si representan un linaje homólogo o un agrupamiento funcional.

Particulares

- Identificar y comparar la arquitectura de dominios de todas las secuencias del grupo utilizando dbCAN, para confirmar la presencia del dominio GH1 y detectar posibles arquitecturas alternativas.
- Evaluar la homogeneidad evolutiva del grupo mediante el análisis de alineamiento múltiple y la detección de secuencias divergentes que no compartan el dominio GH1.

4. Materiales y métodos

Extracción de las secuencias en del grupo K01220 en KEGG

Se utilizará la API de KEGG [16, 15] para la extracción automática de datos. La documentación oficial está disponible en <https://www.kegg.jp/kegg/rest/>. Se desarrollarán scripts en Python (versión 3.12.7), implementados en notebooks de Jupyter (.ipynb), con el objetivo de:

- Extraer las secuencias del grupo K01220.
- Realizar la limpieza de los datos.
- Generar archivos de salida en formato FASTA (.fas).
- Registrar el procesamiento y análisis de los datos.

Todo este código estará disponible en la liga <https://github.com/Electrocyte96/tesina/tree/main/scripts>

Alineamiento múltiple de secuencias

Una vez obtenidas las secuencias en formato FASTA se utilizará el software MEGA11 [23] para realizar un alineamiento múltiple con el algoritmo MUSCLE [4]. El alineamiento permitirá evaluar la conservación de regiones homólogas entre las secuencias y detectar posibles secuencias divergentes dentro del grupo ortólogo analizado.

Búsqueda de dominios conservados con dbCAN

Sobre las secuencias sin alineamiento previo se usará la herramienta dbCAN [29, 28, 11]. Esta plataforma permite identificar clústeres de genes relacionados con carbohidratasas (CGCs), también realizar predicción de sustratos según una determinada secuencia de aminoácidos y permite la anotación de carbohidratasas utilizando perfiles de dominio derivados de la base de datos CAZy (Carbohydrate-Active enZYmes Database). La anotación se llevó a cabo utilizando tres estrategias: búsquedas basadas en modelos ocultos de Markov mediante pyHMMER [18], el cual es una implementación en Python/Cython de HMMER [3]; alineamientos de secuencia mediante DIAMOND [1]; y clasificación en subfamilias mediante dbCAN-sub. Estas estrategias nos permitirán detectar dominios conservados y asignar familias CAZy a cada secuencia analizada y al final obtendremos estos resultados en archivos en formato de Valores Separados por Tabulaciones (.tsv).

Generación de árboles filogenéticos

Para la inferencia filogenética se utilizará la herramienta IQ-TREE [19, 27]. IQ-TREE permite la reconstrucción de árboles filogenéticos mediante métodos de máxima verosimilitud, incorporando selección automática de modelos evolutivos y estimación de soporte estadístico para las ramas. Su uso resulta adecuado debido a su eficiencia computacional y precisión en el análisis de secuencias proteicas homólogas, permitiendo evaluar las relaciones evolutivas entre las proteínas analizadas.

Análisis estructural con DALI

Sobre las secuencias de interés se usará la herramienta en línea DALI server [10] para el análisis estructural de proteínas basándose en un alineamiento de matrices de distancia [8]. Es utilizada ampliamente por cristalógrafos para buscar parentescos de nuevas estructuras proteicas con otras proteínas previamente conocidas y almacenadas en las bases de datos del Protein Data Bank (PDB) y de AlphaFold Database [9] a su vez de apoyarse en Pfam [20] para la anotación de proteínas.

5. Cronograma de actividades (2026)

Del 01 de junio al 21 de junio (Semanas 1 a 3).

- Se utilizará la API de KEGG para la extracción automática de los datos correspondientes a las secuen-

cias del grupo K01220.

- Se desarrollarán los scripts necesarios en Python implementados en notebooks de Jupyter.
- Se realizará la limpieza de los datos para generar de forma eficiente los archivos de salida en formato FASTA.
- Se registrará el procesamiento y análisis de los datos, alojando el código en el repositorio antes mencionado.

Del 22 de junio al 05 de julio (Semanas 4 y 5).

- Se importarán las secuencias en formato FASTA al software MEGA11.
- Se realizará el alineamiento múltiple empleando el algoritmo MUSCLE.
- Se evaluará la conservación de regiones homólogas entre las secuencias.
- Se detectarán y documentarán las posibles secuencias divergentes dentro del grupo ortólogo analizado.

Del 27 de julio al 23 de agosto (Semanas 6 a 9).

- Se procesarán las secuencias sin alineamiento previo utilizando la plataforma dbCAN.
- Se llevará a cabo la anotación de carbohidratasa utilizando perfiles de dominio derivados de la base de datos CAZy.
- Se ejecutarán tres estrategias de anotación: búsquedas basadas en modelos ocultos de Markov mediante pyHMMER, alineamientos de secuencia mediante DIAMOND y clasificación en subfamilias mediante dbCAN-sub.
- Se exportarán los resultados consolidados de dominios conservados y familias CAZy en archivos de Valores Separados por Tabulaciones.

Del 24 de agosto al 20 de septiembre (Semanas 10 a 13).

- Se reconstruirán los árboles filogenéticos utilizando la herramienta IQ-TREE.
- Se aplicarán métodos de máxima verosimilitud para la estimación de soporte estadístico en las ramas.
- Se automatizará la selección de modelos evolutivos a través de la plataforma, lo que permitirá enfocar el análisis directamente en la lógica biológica de las relaciones evolutivas.

Del 21 de septiembre al 11 de octubre (Semanas 14 a 16).

- Se utilizará la herramienta en línea DALI server para el análisis estructural de las secuencias de interés.
- Se basará el análisis en un alineamiento de matrices de distancia para buscar parentescos con estructuras proteicas previamente conocidas.
- Se cruzará la información con las bases de datos de AlphaFold Database, Protein Data Bank (PDB) y Pfam para consolidar la anotación de proteínas.
- Se escribirá el manuscrito de la tesina y se generarán las figuras pertinentes para la representación y presentación clara de los resultados obtenidos.

6. Referencias

- [1] Benjamin Buchfink, Klaus Reuter y Hajk-Georg Drost. «Sensitive protein alignments at tree-of-life scale using DIAMOND». En: *Nature Methods* 18.4 (2021), págs. 366-368. ISSN: 1548-7105. DOI: 10.1038/s41592-021-01101-x.
- [2] M.O. Dayhoff. «The origin and evolution of protein superfamilies». En: *Federation proceedings* 35.10 (1976), págs. 2132-2138.
- [3] Sean R. Eddy. «Accelerated Profile HMM Searches». En: *PLoS Computational Biology* 7.10 (2011). Ed. por William R. Pearson, e1002195. ISSN: 1553-7358. DOI: 10.1371/journal.pcbi.1002195.
- [4] R. C. Edgar. «MUSCLE: multiple sequence alignment with high accuracy and high throughput». En: *Nucleic Acids Research* 32.5 (2004), págs. 1792-1797. ISSN: 1362-4962. DOI: 10.1093/nar/gkh340.
- [5] Walter M. Fitch. «Distinguishing Homologous from Analogous Proteins». En: *Systematic Zoology* 19.2 (1970), pág. 99. ISSN: 0039-7989. DOI: 10.2307/2412448.
- [6] A.V. Fowler e I. Zabin. «Amino acid sequence of beta-galactosidase. XI. Peptide ordering procedures and the complete sequence». En: *Journal of Biological Chemistry* 253.15 (1978), págs. 5521-5525. ISSN: 0021-9258. DOI: 10.1016/S0021-9258(17)30405-2.
- [7] Bernard Henrissat y Gideon Davies. «Structural and sequence-based classification of glycoside hydrolases». En: *Current Opinion in Structural Biology* 7.5 (1997), págs. 637-644. ISSN: 0959-440X. DOI: 10.1016/S0959-440X(97)80072-3.
- [8] Liisa Holm. «DALI and the persistence of protein shape». En: *Protein Science* 29.1 (2019), págs. 128-140. ISSN: 1469-896X. DOI: 10.1002/pro.3749.
- [9] Liisa Holm. «Dali server: structural unification of protein families». En: *Nucleic Acids Research* 50.W1 (2022), W210-W215. ISSN: 1362-4962. DOI: 10.1093/nar/gkac387.
- [10] Liisa Holm et al. «DALI shines a light on remote homologs: One hundred discoveries». En: *Protein Science* 32.1 (2022). ISSN: 1469-896X. DOI: 10.1002/pro.4519.
- [11] Le Huang et al. «dbCAN-seq: a database of carbohydrate-active enzyme (CAZyme) sequence and annotation». En: *Nucleic Acids Research* 46.D1 (2017), págs. D516-D521. ISSN: 1362-4962. DOI: 10.1093/nar/gkx894.

- [12] Douglas H. Juers, Brian W. Matthews y Reuben E. Huber. «LacZ β -galactosidase: Structure and function of an enzyme of historical and molecular biological importance». En: *Protein Science* 21.12 (2012), págs. 1792-1807. ISSN: 1469-896X. DOI: 10.1002/pro.2165.
- [13] M Kanehisa y G. Susumu. «KEGG: Kyoto Encyclopedia of Genes and Genomes». En: *Nucleic Acids Research* 28.1 (ene. de 2000), págs. 27-30. ISSN: 1362-4962. DOI: 10.1093/nar/28.1.27.
- [14] Minoru Kanehisa. «A database for post-genome analysis». En: *Trends in Genetics* 13.9 (1997), págs. 375-376. ISSN: 0168-9525. DOI: 10.1016/s0168-9525(97)01223-7.
- [15] Minoru Kanehisa et al. «KEGG for taxonomy-based analysis of pathways and genomes». En: *Nucleic Acids Research* 51.D1 (2022), págs. D587-D592. ISSN: 1362-4962. DOI: 10.1093/nar/gkac963.
- [16] Minoru Kanehisa et al. «The KEGG resource for deciphering the genome». En: *Nucleic Acids Research* 32.90001 (2004), págs. 277D-280. ISSN: 1362-4962. DOI: 10.1093/nar/gkh063.
- [17] Eugene V. Koonin. «Orthologs, Paralogs, and Evolutionary Genomics». En: *Annual Review of Genetics* 39.1 (2005), págs. 309-338. ISSN: 1545-2948. DOI: 10.1146/annurev.genet.39.073003.114725.
- [18] Martin Larralde y Georg Zeller. «PyHMMER: a Python library binding to HMMER for efficient sequence analysis». En: *Bioinformatics* 39.5 (2023). Ed. por Can Alkan. ISSN: 1367-4811. DOI: 10.1093/bioinformatics/btad214.
- [19] Bui Quang Minh et al. «IQ-TREE 2: New Models and Efficient Methods for Phylogenetic Inference in the Genomic Era». En: *Molecular Biology and Evolution* 37.5 (2020). Ed. por Emma Teeling, págs. 1530-1534. ISSN: 1537-1719. DOI: 10.1093/molbev/msaa015.
- [20] Jaina Mistry et al. «Pfam: The protein families database in 2021». En: *Nucleic Acids Research* 49.D1 (2020), págs. D412-D419. ISSN: 1362-4962. DOI: 10.1093/nar/gkaa913.
- [21] C Ouzounis. «Orthology: another terminology muddle». En: *Trends in Genetics* 15.11 (1999), pág. 445. ISSN: 0168-9525. DOI: 10.1016/s0168-9525(99)01845-4.
- [22] Gregory A Petsko. «Homologuephobia». En: *Genome Biology* 2.2 (2001), comment1002.1. ISSN: 1465-6906. DOI: 10.1186/gb-2001-2-2-comment1002.
- [23] Koichiro Tamura, Glen Stecher y Sudhir Kumar. «MEGA11: Molecular Evolutionary Genetics Analysis Version 11». En: *Molecular Biology and Evolution* 38.7 (2021). Ed. por Fabia Ursula Battistuzzi, págs. 3022-3027. ISSN: 1537-1719. DOI: 10.1093/molbev/msab120.
- [24] Roman L. Tatusov, Eugene V. Koonin y David J. Lipman. «A Genomic Perspective on Protein Families». En: *Science* 278.5338 (1997), págs. 631-637. ISSN: 1095-9203. DOI: 10.1126/science.278.5338.631.
- [25] H.G Vázquez-López y P. Alvarez-Gutierrez. «Homology and convergence in β -galactosidases». En: (2023).
- [26] Caleb Webber y Chris P Ponting. «Genes and homology». En: *Current Biology* 14.9 (2004), R332-R333. ISSN: 0960-9822. DOI: 10.1016/j.cub.2004.04.016.
- [27] Thomas Wong et al. «IQ-TREE 3: Phylogenomic Inference Software using Complex Evolutionary Models». En: (2025). DOI: 10.32942/X2P62N.

- [28] Han Zhang et al. «dbCAN2: a meta server for automated carbohydrate-active enzyme annotation». En: *Nucleic Acids Research* 46.W1 (2018), W95-W101. ISSN: 1362-4962. DOI: 10.1093/nar/gky418.
- [29] Jinfang Zheng et al. «dbCAN3: automated carbohydrate-active enzyme and substrate annotation». En: *Nucleic Acids Research* 51.W1 (2023), W115-W121. ISSN: 1362-4962. DOI: 10.1093/nar/gkad328.

7. Firmas

Firma del alumno

Jesús Jacob García Medrano

Firma del asesor

Dr. Héctor Gilberto Vázquez López