



UNIVERSIDAD NACIONAL AUTÓNOMA
DE MÉXICO

FACULTAD DE CIENCIAS

Análisis filogenético y revisión sobre la homología de
diferentes representantes de una familia de proteínas que
degradan lactosa.

T E S I N A

QUE PARA OBTENER EL TÍTULO DE:

B I Ó L O G O

P R E S E N T A:

JESÚS JACOB GARCÍA MEDRANO

DIRECTOR DE TESINA:

DR. HÉCTOR GILBERTO VÁZQUEZ LÓPEZ

2026



Índice general

RESUMEN	4
1. Introducción	5
1.1. Sub indice generico	5
1.2. Sub indice generico	5
1.2.1. Sub subindice	5
1.3. Sub indice generico	5
2. Objetivos	6
2.1. Objetivo General	6
2.1.1. Objetivos Específicos	6
3. Desarrollo	7
3.1. Materiales y métodos	7
3.1.1. Extracción de las secuencias	7
3.1.2. Extracción de los datos de los organismos	7
3.1.3. Manipulación de las secuencias	7
3.1.4. Alineamiento en MEGA	8
3.1.5. Secuencia consenso	8
3.1.6. Búsqueda en InterPro/Pfam y PDB	8
3.1.7. Alineamiento pairwise	8
3.1.8.	8

Índice de figuras

RESUMEN

Aquí va el resumen o abstract...

1. Introducción

Esta sería la introducción del texto

1.1. Sub índice generico

Sección de la intro

1.2. Sub índice generico

Otra sección de la intro

1.2.1. Sub subíndice

Este sería un sub sub índice que por el momento no lo renderiza

1.3. Sub índice generico

veamos que pasa si meto un sub índice después de un sub subíndice

2. Objetivos

2.1. Objetivo General

Evaluar la validez evolutiva del grupo de ortólogos anotados como 6-fosfo- β -galactosidasa (GH1) en KEGG (Kanehisa et al., 2004), definido como K01220, mediante el análisis de arquitectura de dominios y comparativa múltiple, para reconocer posibles señales de divergencia e innovación de genes homólogos recientes o reconocer solo agrupamiento funcional por parte de reportes previos

2.1.1. Objetivos Específicos

- Identificar y comparar la arquitectura de dominios de todas las secuencias del grupo utilizando dbCAN (Huang et al., 2017; Zhang et al., 2018), para confirmar la presencia de del dominio GH1 y detectar posibles arquitecturas alternativas, dentro de genomas completamente secuenciados en la base de datos de genes y genomas de Kyoto.
- Evaluar la homogeneidad evolutiva del grupo mediante el análisis de alineamiento múltiple (Edgar, 2004; Tamura et al., 2021), identificación de elementos duplicados y la detección de secuencias divergentes que no compartan el dominio GH1 o que pudiesen denotar información equivocada o incierta dentro de reportes y bases de datos previamente reportadas.

3. Desarrollo

3.1. Materiales y métodos

La extracción de las secuencias, los datos de los organismos y el procesamiento de la información descargada se realizaron en cuadernillos de Python (archivos con extensión .ipynb y referidos de aquí en adelante simplemente como cuadernillos) utilizando el entorno Jupyter Notebook v7.6.2 (Thomas et al., 2016) sobre Python v3.10.0. El funcionamiento detallado del código se encuentra documentado dentro de cada archivo, y todos los recursos generados están disponibles en el repositorio <https://github.com/Electrocyte96/tesina/tree/main/scripts>.

3.1.1. Extracción de las secuencias

Con el fin de obtener las secuencias para todo el estudio se creó el cuadernillo «`sequence_extraction.ipynb`» con la idea de hacer múltiples peticiones de tipo GET a la API de KEGG (Kanehisa et al., 2004) para que al final se obtuviera un archivo de tipo valores separados por comas o texto (csv o txt respectivamente) con las secuencias. El archivo generado lleva por nombre «`K01220.txt`».

3.1.2. Extracción de los datos de los organismos

Con el propósito de complementar la información obtenida en el paso anterior se creó un cuadernillo llamado «`all_organisms.ipynb`» que también se comunica a la API de KEGG (Kanehisa et al., 2004), hace una petición de tipo GET y obtiene datos de los organismos reportados en KEGG (Kanehisa et al., 2004), por ejemplo, el nombre científico, su filogenia (hasta cierto nivel), etc. Este procedimiento devuelve un archivo txt llamado «`organismos.txt`» que contiene la nueva información de los organismos, la idea detrás de esto es poder hacer mejores encabezados (headers) para cada secuencia en un archivo FASTA (fas).

3.1.3. Manipulación de las secuencias

Después de la extracción de las secuencias y datos de los organismos es necesario juntar esta información para así generar los archivos fas para hacer análisis posteriores. Para esto se creó el archivo «`data_wrangling.ipynb`», que como resultado genera dos archivos fas, con los datos del organismo en el header (con nombre científico y gen) y su respectiva secuencia, esta puede ser de aminoácidos o nucleótidos, para cada caso fueron llamados «`k01220_aa_names.fas`» y «`k01220_nt_names.fas`».

3.1.4. Alineamiento en MEGA

Para generación del alineamiento con las secuencias se utilizó el programa MEGA 11 (Tamura et al., 2021), se usaron los parámetros por default para el alineamiento y estos fueron los siguientes:

- Algoritmo MUSCLE (Edgar, 2004).
- Gap Open: -2.90.
- Gap Extend: 0.00.
- Hydrophobicity Multiplier: 1.20.
- Max Iterations: 16.
- Cluster Method: UPGMA.

Se realizó alineamiento sobre las secuencias tanto de aminoácidos como de nucleótidos. Estos alineamientos se guardarán en nuevos archivos con nombre «k01220_aa_names_aligned.fas» para el alineamiento de secuencias de aminoácidos y «k01220_nt_names_aligned.fas» para el alineamiento de secuencias de nucleótidos.

3.1.5. Secuencia consenso

Para la obtención de una secuencia consenso a partir de todas las secuencias de aminoácidos guardadas en «k01220_aa_names_aligned.fas» se creó el cuadernillo «consensus_sequences.ipynb», donde se escribió el código necesario para la generación de una secuencia consenso. Los parámetros que se usaron para la obtención de esta secuencia fueron:

- Un aminoácido debe estar presente en al menos el 50 % de las secuencias totales.
- Si dos aminoácidos (o más) están empatados en la frecuencia de aparición a lo largo de todas las secuencias, entonces se agregará un gap (-).

3.1.6. Búsqueda en InterPro/Pfam y PDB

3.1.7. Alineamiento pairwise

3.1.8.

Referencias

- Edgar, R. C. (2004). MUSCLE: multiple sequence alignment with high accuracy and high throughput. *Nucleic Acids Research*, 32(5), 1792-1797. <https://doi.org/10.1093/nar/gkh340>
- Huang, L., Zhang, H., Wu, P., Entwistle, S., Li, X., Yohe, T., Yi, H., Yang, Z., & Yin, Y. (2017). dbCAN-seq: a database of carbohydrate-active enzyme (CAZyme) sequence and annotation. *Nucleic Acids Research*, 46(D1), D516-D521. <https://doi.org/10.1093/nar/gkx894>
- Kanehisa, M., Susumu, G., Shuichi, K., Yasushi, O., & Masahiro, H. (2004). The KEGG resource for deciphering the genome. *Nucleic Acids Research*, 32(90001), 277D-280. <https://doi.org/10.1093/nar/gkh063>
- Tamura, K., Stecher, G., & Kumar, S. (2021). MEGA11: Molecular Evolutionary Genetics Analysis Version 11 (F. U. Battistuzzi, Ed.). *Molecular Biology and Evolution*, 38(7), 3022-3027. <https://doi.org/10.1093/molbev/msab120>
- Thomas, K., Benjamin, R.-K., Fernando, P., Brian, G., Matthias, B., Jonathan, F., Kyle, K., Jessica, H., Jason, G., Sylvain, C., Paul, I., Damián, A., Safia, A., Carol, W., & Team, J. D. (2016). Jupyter Notebooks a publishing format for reproducible computational workflows. <https://doi.org/10.3233/978-1-61499-649-1-87>
- Zhang, H., Yohe, T., Huang, L., Entwistle, S., Wu, P., Yang, Z., Busk, P. K., Xu, Y., & Yin, Y. (2018). dbCAN2: a meta server for automated carbohydrate-active enzyme annotation. *Nucleic Acids Research*, 46(W1), W95-W101. <https://doi.org/10.1093/nar/gky418>