



**UNIVERSIDAD NACIONAL AUTÓNOMA
DE MÉXICO**

FACULTAD DE CIENCIAS

**Análisis filogenético y revisión sobre la homología de
diferentes representantes de una familia de proteínas que
degradan lactosa.**

T E S I N A

QUE PARA OBTENER EL TÍTULO DE:

B I Ó L O G O

P R E S E N T A:

JESÚS JACOB GARCÍA MEDRANO

DIRECTOR DE TESINA:

DR. HÉCTOR GILBERTO VÁZQUEZ LÓPEZ

2026



Índice general

RESUMEN	3
1. Introducción	4
2. Objetivos	5
2.1. Objetivo General	5
2.1.1. Objetivos Específicos	5
3. Desarrollo	6
3.1. Materiales y métodos	6
3.1.1. Extracción de las secuencias	6
3.1.2. Extracción de los datos de los organismos	6
3.1.3. Manipulación de las secuencias	6
3.1.4. Alineamiento en MEGA	7
3.1.5. Secuencia consenso	7
3.1.6. Búsqueda en InterProScan	8
3.1.7. Búsqueda en PDB	8
3.1.8. Alineamiento de secuencia consenso Vs. secuencia de estructura PDB	8
3.1.9. Visualización de estructuras o residuos	8
Referencias	9

Índice de figuras

RESUMEN

Aquí va el resumen o abstract...

1. Introducción

Esta sería la introduccion del texto

2. Objetivos

2.1. Objetivo General

Evaluar la validez evolutiva del grupo de ortólogos anotados como 6-fosfo- β -galactosidasa (GH1) en KEGG (Kanehisa et al., 2004), definido como K01220, mediante el análisis de arquitectura de dominios y comparativa múltiple, para reconocer posibles señales de divergencia e innovación de genes homólogos recientes o reconocer solo agrupamiento funcional por parte de reportes previos

2.1.1. Objetivos Específicos

- Identificar y comparar la arquitectura de dominios de todas las secuencias del grupo utilizando dbCAN (Huang et al., 2017; Zhang et al., 2018), para confirmar la presencia de del dominio GH1 y detectar posibles arquitecturas alternativas, dentro de genomas completamente secuenciados en la base de datos de genes y genomas de Kyoto.
- Evaluar la homogeneidad evolutiva del grupo mediante el análisis de alineamiento múltiple (Edgar, 2004; Tamura et al., 2021), identificación de elementos duplicados y la detección de secuencias divergentes que no compartan el dominio GH1 o que pudiesen denotar información equivocada o incierta dentro de reportes y bases de datos previamente reportadas.

3. Desarrollo

3.1. Materiales y métodos

La extracción de las secuencias, los datos de los organismos y el procesamiento de la información descargada se realizaron en cuadernillos de Python (archivos con extensión .ipynb y referidos de aquí en adelante simplemente como cuadernillos) utilizando el entorno Jupyter Notebook v7.6.2 (Thomas et al., 2016) sobre Python v3.10.0. El funcionamiento detallado del código se encuentra documentado dentro de cada archivo, y todos los recursos generados están disponibles en el repositorio: <https://github.com/Electrocyte96/tesina/tree/main/scripts>.

3.1.1. Extracción de las secuencias

Con el fin de obtener las secuencias para todo el estudio se creó el cuadernillo «`sequence_extraction.ipynb`» con la idea de hacer múltiples peticiones de tipo GET a la API de KEGG (Kanehisa et al., 2004) para que al final se obtuviera un archivo de tipo valores separados por comas o texto (csv o txt respectivamente) con las secuencias. El archivo generado lleva por nombre «`K01220.txt`».

3.1.2. Extracción de los datos de los organismos

Con el propósito de complementar la información obtenida en el paso anterior se creó un cuadernillo llamado «`all_organisms.ipynb`» que también se comunica a la API de KEGG (Kanehisa et al., 2004), hace una petición de tipo GET y obtiene datos de los organismos reportados en KEGG (Kanehisa et al., 2004), por ejemplo, el nombre científico, su filogenia (hasta cierto nivel), etc. Este procedimiento devuelve un archivo txt llamado «`organismos.txt`» que contiene la nueva información de los organismos, la idea detrás de esto es poder hacer mejores encabezados (headers) para cada secuencia en un archivo FASTA (fas).

3.1.3. Manipulación de las secuencias

Después de la extracción de las secuencias y datos de los organismos es necesario juntar esta información para así generar los archivos fas para hacer análisis posteriores. Para esto se creó el cuadernillo «`data_wrangling.ipynb`», que como resultado genera dos archivos fas, con los datos del organismo en el header (con nombre científico y gen) y su respectiva secuencia, esta puede ser de aminoácidos o nucleótidos, para cada caso fueron llamados «`k01220_aa_names.fas`» y «`k01220_nt_names.fas`».

3.1.4. Alineamiento en MEGA

Para generación del alineamiento con las secuencias se utilizó el programa MEGA 11 (Tamura et al., 2021), se usaron los parámetros por default para el alineamiento y estos fueron los siguientes:

- Algoritmo MUSCLE (Edgar, 2004).
- Gap Open: -2.90.
- Gap Extend: 0.00.
- Hydrophobicity Multiplier: 1.20.
- Max Iterations: 16.
- Cluster Method: UPGMA.

Se realizó el alineamiento sobre las secuencias tanto de aminoácidos como de nucleótidos. Estos alineamientos se guardarán en nuevos archivos con nombre «k01220_aa_names_aligned.fas» para el alineamiento de secuencias de aminoácidos y «k01220_nt_names_aligned.fas» para el alineamiento de secuencias de nucleótidos.

3.1.5. Secuencia consenso

Para la obtención de una secuencia consenso a partir de todas las secuencias de aminoácidos guardadas en «k01220_aa_names_aligned.fas» se creó el cuadernillo «consensus_sequences.ipynb», donde se escribió el código necesario para la generación de una secuencia consenso. Los parámetros que se usaron para la obtención de esta secuencia fueron:

- Un aminoácido debe estar presente en al menos el 50 % de las secuencias totales.
- Si dos aminoácidos (o más) están empatados en la frecuencia de aparición a lo largo de todas las secuencias, entonces se agregará un gap (-).

Al final se generaron un par de archivos, «consensus_threshold_50.fas» y «consensus_threshold_50.txt», ambas contienen la secuencia consenso la diferencia es que el archivo fas tiene header y un separador. De la misma forma se crearon dos versiones más de estos mismos archivos solo con la diferencia de que no contienen gaps (-) en la secuencia, a estos archivos se les llamó «consensus_threshold_50_no_gaps.fas» y «consensus_threshold_50_no_gaps.txt».

3.1.6. Búsqueda en InterProScan

Una vez obtenida la secuencia consenso (ya sea con o sin gaps), se utilizó el servicio en línea de InterProScan (Blum et al., 2026) versión 6.0.2.2 para la confirmación de su anotación, predicción de la arquitectura de dominios, familias de proteínas, motivos y sitios activos, etc. Este recurso es una de las herramientas pertenecientes a InterPro (Blum et al., 2024) que funciona como un programa de clasificación de proteínas a gran escala. Al terminar el análisis, InterProScan (Blum et al., 2026) nos devolvió todos los resultados de nuestra búsqueda, es decir, todas las coincidencias entre nuestra secuencia consenso y algunas bases de datos en las que se apoya InterProScan. Estos resultados estuvieron disponibles para descargarlos en un formato de texto conveniente (xml, json, tsv, entre otros). En este caso se decidió optar por el formato json y se le dio el nombre de «interproscan.json». Posteriormente se creó el cuadernillo «interpro_domains.ipynb» para la extracción automática de algunas regiones o aminoácidos de interés encontrados.

3.1.7. Búsqueda en PDB

De la misma forma, la secuencia consenso libre de gaps se utilizó para iniciar una búsqueda de similitud (Sequence Similarity Search) en el Protein Data Bank (PDB) (Vallat et al., 2025). La plataforma PDB ejecuta esta búsqueda utilizando MMseqs2 (Steinegger & Söding, 2017), una serie ordenada de algoritmos que permiten el agrupamiento y alineamiento global de secuencias. Como resultado, se seleccionó el modelo con el mayor porcentaje de identidad (79 %), el cual correspondió a la estructura cristalográfica de la 6-fosfo-beta-galactosidasa (PDB ID: 1PBG) del organismo *Lactococcus lactis* (Wiesmann et al., 1995). La entrada 1PBG consta de un homodímero (dos cadenas polipeptídicas) y conserva un ligando sulfato (SO_4^{2-}) cocrystalizado en su estructura.

Desde la entrada oficial de 1PBG se descargó el modelo de coordenadas atómicas en formato pdb (Legacy PDB). Debido a su naturaleza pública este archivo no se incluyó en el repositorio de la Tesina. Adicionalmente, se descargó la secuencia original del polipéptido cristalizado en formato FASTA, la cual se renombró como «1PBG_sequence.fas» para los análisis posteriores.

3.1.8. Alineamiento de secuencia consenso Vs. secuencia de estructura PDB

Se creó el cuadernillo «pairwise_alignment.ipynb» para realizar un alineamiento global entre la secuencia consenso, «consensus_threshold_50.fas» y la secuencia de nuestra estructura PDB, «1PBG_sequence.fas», esto con el fin de poder hacer comparables ambas secuencias en términos de índices (o coordenadas). Para esta tarea se utilizó el modulo Bio.Align de la librería Biopython (Cock et al., 2009) de Python.

3.1.9. Visualización de estructuras o residuos

Referencias

- Blum, M., Andreeva, A., Florentino, L. C., Chuguransky, S. R., Grego, T., Hobbs, E., Pinto, B. L., Orr, A., Paysan-Lafosse, T., Ponamareva, I., Salazar, G. A., Bordin, N., Bork, P., Bridge, A., Colwell, L., Gough, J., Haft, D. H., Letunic, I., Llinares-López, F., ... Bateman, A. (2024). InterPro: the protein sequence classification resource in 2025. *Nucleic Acids Research*, 53(D1), D444-D456. <https://doi.org/10.1093/nar/gkae1082>
- Blum, M., Hobbs, E., Florentino, L., & Bateman, A. (2026). InterProScan 6: a modern large-scale protein function annotation pipeline (M. Adebisi, Ed.). *Bioinformatics Advances*, 6(1). <https://doi.org/10.1093/bioadv/vbag141>
- Cock, P. J. A., Antao, T., Chang, J. T., Chapman, B. A., Cox, C. J., Dalke, A., Friedberg, I., Hamelryck, T., Kauff, F., Wilczynski, B., & de Hoon, M. J. L. (2009). Biopython: freely available Python tools for computational molecular biology and bioinformatics. *Bioinformatics*, 25(11), 1422-1423. <https://doi.org/10.1093/bioinformatics/btp163>
- Edgar, R. C. (2004). MUSCLE: multiple sequence alignment with high accuracy and high throughput. *Nucleic Acids Research*, 32(5), 1792-1797. <https://doi.org/10.1093/nar/gkh340>
- Huang, L., Zhang, H., Wu, P., Entwistle, S., Li, X., Yohe, T., Yi, H., Yang, Z., & Yin, Y. (2017). dbCAN-seq: a database of carbohydrate-active enzyme (CAZyme) sequence and annotation. *Nucleic Acids Research*, 46(D1), D516-D521. <https://doi.org/10.1093/nar/gkx894>
- Kanehisa, M., Susumu, G., Shuichi, K., Yasushi, O., & Masahiro, H. (2004). The KEGG resource for deciphering the genome. *Nucleic Acids Research*, 32(90001), 277D-280. <https://doi.org/10.1093/nar/gkh063>
- Steinegger, M., & Söding, J. (2017). MMseqs2 enables sensitive protein sequence searching for the analysis of massive data sets. *Nature Biotechnology*, 35(11), 1026-1028. <https://doi.org/10.1038/nbt.3988>
- Tamura, K., Stecher, G., & Kumar, S. (2021). MEGA11: Molecular Evolutionary Genetics Analysis Version 11 (F. U. Battistuzzi, Ed.). *Molecular Biology and Evolution*, 38(7), 3022-3027. <https://doi.org/10.1093/molbev/msab120>
- Thomas, K., Benjamin, R.-K., Fernando, P., Brian, G., Matthias, B., Jonathan, F., Kyle, K., Jessica, H., Jason, G., Sylvain, C., Paul, I., Damián, A., Safia, A., Carol, W., & Team, J. D. (2016). Jupyter Notebooks a publishing format for reproducible computational workflows. <https://doi.org/10.3233/978-1-61499-649-1-87>
- Vallat, B., Rose, Y., Piehl, D. W., Duarte, J. M., Bittrich, S., Bi, C., Segura, J., Zalevsky, A., Sekharan, M. R., Webb, B. M., Bhikadiya, C., Voigt, M., Henry, J., Chao, H., Pingale, A., Raymond, D., Sagendorf, J.,

- Peisach, E., Feng, Z., ... Burley, S. K. (2025). RCSB Protein Data Bank: Delivering integrative structures alongside experimental structures and computed structure models. *Nucleic Acids Research*, 54(D1), D489-D498. <https://doi.org/10.1093/nar/gkaf1187>
- Wiesmann, C., Beste, G., Hengstenberg, W., & Schulz, G. E. (1995). The three-dimensional structure of 6-phospho- β -galactosidase from *Lactococcus lactis*. *Structure*, 3(9), 961-968. [https://doi.org/10.1016/S0969-2126\(01\)00230-1](https://doi.org/10.1016/S0969-2126(01)00230-1)
- Zhang, H., Yohe, T., Huang, L., Entwistle, S., Wu, P., Yang, Z., Busk, P. K., Xu, Y., & Yin, Y. (2018). dbCAN2: a meta server for automated carbohydrate-active enzyme annotation. *Nucleic Acids Research*, 46(W1), W95-W101. <https://doi.org/10.1093/nar/gky418>